


Module : Bio-Informatique



Rapport de Projet
Ancestry prediction based on 1000 genome or 23 and Megenome
Par Apprentissage Automatique

Réaliser par :

Dellaji Hiba

Houali Malak

Chabbaki Aymen

Ben Difi Mohamed

Encadrer par :

Pr. Benamri Ichrak

Table des matières

Introduction Générale.....	6
Introduction Générale.....	7
Chapitre 1 :	9
Contexte générale et cahier de charge	9
1. Contexte Général du Projet	10
1.1. Fondements Scientifiques et Données de Référence	10
2. Cahier des Charges et Exigences du Système	10
2.1. Spécifications Techniques et Contraintes de Développement	11
3. Problématiques et besoins	11
4. Objectifs	11
5. Déroulement du projet.....	11
6. GANTT	12
7. Distribution de rôles	12
8. Méthodologie de gestion	12
9. Conclusion.....	13
Chapitre 2 :	14
Exploration des fondamentaux et des domaines de l'intelligence artificielle	14
1. Domaines de l'intelligence artificielle	15
2. Machine Learning	15
3. Les méthodes de machine learning	16
3.1. Apprentissage supervisé.....	16
3.2. Apprentissage non supervisé.....	17
3.3. Apprentissage semi-supervisé.....	17
3.4. Apprentissage par renforcement	17
4. Intelligence artificielle dans le domaine de la santé.....	17
5. Avantages et limites des systèmes intelligents dans le domaine de la santé	18
6. Ingénierie des caractéristiques et réduction de dimensionnalité	18
7. Classification Statistique et Inférence de Probabilités	19
8. Domaines d'application : De la recherche à la mise en production.....	19
9. Conclusion.....	19
Chapitre 3 :	21
Élaboration et Préparation du Dataset	21
1. Introduction du Dataset	22
2. Préparation et téléchargement des données.....	22

3. Méthodes de nettoyage du dataset.....	23
4. Prétraitement et normalisation	24
4.1. Normalisation des données	24
4.2. Imputation des valeurs manquantes	25
5. Réduction de dimension : PCA (Analyse en Composantes Principales)	25
6. Choix de l'algorithme.....	26
5. Bibliothèques utilisées	27
5.1 Gestion des fichiers et des données	28
5.2 Manipulation et traitement des données.....	28
5.3 Chargement et utilisation des modèles.....	28
5.4 Conversion des coordonnées génomiques	29
6. Architecture du système : Analyse de l'ancestralité génomique.....	29
7. Analyse des Diagrammes UML	31
7.1. Diagramme de Cas d'Utilisation (Use Case)	32
7.2. Diagramme de Séquence.....	33
8. Architecture Réseau et Sécurité des Données	35
8.1. Traitement des requêtes et orchestration serveur	36
8.2. Garantie de sécurité et isolation des composants.....	36
9. Architecture Décisionnelle et Modèles BI.....	37
9.1. Le Modèle de Données : Schéma en Étoile	38
9.2. Architecture BI et Flux de Données.....	39
9.3. Indicateurs de Performance et Visualisations	40
10. Conclusion.....	42
Chapitre 4 :	43
Implémentation et résultats	43
1. Implémentation Technique	44
2. Courbe d'Apprentissage (Learning Curve)	44
2.1. Analyse de la performance.....	45
3. Interface Utilisateur	45
3.1. Interface Utilisateur et Sécurité.....	45
3.2. Orchestration et Flux de Traitement	46
4. Analyse des Résultats et KPIs	47
4.1. Indicateurs de Performance (KPIs)	47
4.2. Visualisations Décisionnelles	48
5. Interprétation des Résultats	49

6. Limites du Modèle	49
7. Contraintes Techniques et Opérationnelles	49
8. Conclusion.....	50
Chapitre 5 :	51
Conclusion Générale	51
Conclusion Générale.....	52
Bibliographie	53

Liste Figures

Figure 1:Diagramme GANTT	12
Figure 2: Domaines de l'intelligence artificielle	15
Figure 3: Processus Machine Learning	16
Figure 4: Les méthodes de machine learning	17
Figure 5: Préparation et téléchargement des données	22
Figure 6: Téléchargement des données	23
Figure 7:Normalisation des données	25
Figure 8: bibliothèque sys python	27
Figure 9: bibliothèque json python.....	27
Figure 10: bibliothèque joblib python.....	27
Figure 11: bibliothèque Numpy python	27
Figure 12: bibliothèque pandas python	28
Figure 13: bibliothèque os python.....	28
Figure 14: bibliothèque pvlb python	28
Figure 15: Architecture du système	31
Figure 16:Diagramme de Cas d'Utilisation	33
Figure 17: Diagramme de Séquence	35
Figure 18:Architecture Réseau et Sécurité des Données.....	37
Figure 19:Le Modèle de Données : Schéma en Étoile	39
Figure 20:Architecture BI et Flux de Données	40
Figure 21:Indicateurs de Performance et Visualisations.....	40
Figure 22:Popularité des formats de fichiers Bar Chart	41
Figure 23:kpi structure	42
Figure 24:Learning Curve	44
Figure 25:Interface Utilisateur	46
Figure 26: Visualisations Décisionnelles Interface Utilisateur	48

Introduction Générale

Introduction Générale

Le domaine de la génomique personnelle a connu une expansion fulgurante, permettant aujourd'hui à des millions d'individus d'accéder à leurs données ADN brutes via des services de génotypage grand public. Le projet Genetic Ancestry Inference s'inscrit dans cette révolution biotechnologique, où l'interprétation de la variabilité génétique humaine devient un enjeu majeur. L'objectif est de traiter des données de polymorphismes nucléotidiques (SNPs) pour retracer l'histoire migratoire et les origines biogéographiques d'un individu. Ce travail se base sur l'exploitation des données de référence mondiales, notamment celles du projet 1000 Genomes, pour construire un pont entre la donnée biologique brute et l'information ancestrale. Ce projet est réalisé dans un cadre académique de Master spécialisé en Intelligence Artificielle et Big Data, mettant l'accent sur l'application pratique des sciences des données et de l'apprentissage automatique au domaine de la bioinformatique.

La problématique centrale réside dans l'hétérogénéité et la complexité des données génomiques. Les fichiers fournis par des sociétés comme 23andMe ou AncestryDNA utilisent des formats et des référentiels génomiques, souvent hg19, qui diffèrent des standards de recherche actuels. Il existe donc un besoin critique pour une solution capable d'automatiser l'harmonisation de ces données via le processus de liftover, d'extraire les marqueurs pertinents parmi des milliers de SNPs, et de fournir une analyse statistique fiable sans compromettre la confidentialité des données sensibles de l'utilisateur.

L'objectif principal est de développer une plateforme full-stack capable d'inférer l'ascendance génétique avec une précision élevée. Cela implique la mise en place d'un pipeline de Machine Learning robuste utilisant l'Analyse en Composantes Principales (PCA) pour la réduction de dimension et la Régression Logistique pour la classification en super-populations mondiales. Un objectif technique majeur est également de garantir une architecture Privacy-by-Design, où le traitement s'effectue intégralement en mémoire vive pour protéger l'anonymat des données traitées.

Le résultat final attendu est une application fonctionnelle permettant à un utilisateur de télécharger son génome et d'obtenir une répartition précise de ses origines parmi les populations africaines, américaines, asiatiques et européennes. L'impact du projet est double : il démontre la puissance de l'IA dans l'interprétation de données biologiques complexes et offre un outil

pédagogique accessible pour comprendre la diversité génétique humaine. À plus large échelle, cette méthodologie peut être étendue à la médecine personnalisée ou à l'étude des risques héréditaires.

Ce rapport est structuré de manière à retracer chaque étape du cycle de vie du projet. Il débute par une exploration des fondamentaux de l'intelligence artificielle appliqués à la génomique. La section suivante détaille l'analyse technique et l'architecture logicielle adoptée, incluant le backend en Node.js et l'intégration des modèles Python. Enfin, le rapport se conclut par la présentation de la réalisation, des phases de tests et d'une analyse critique des résultats obtenus par le modèle de prédiction.

Chapitre 1 :

Contexte générale et cahier de charge

1. Contexte Général du Projet

Le projet Genetic Ancestry Inference s'inscrit à l'intersection de la bioinformatique et de l'intelligence artificielle, répondant à un besoin croissant de démocratisation de l'analyse génomique personnelle. Avec l'essor des technologies de génotypage à haut débit, des millions d'utilisateurs disposent désormais de fichiers de données brutes contenant des centaines de milliers de polymorphismes nucléotidiques (SNPs). Toutefois, ces informations demeurent inexploitable pour un non-expert sans l'intervention d'outils de calcul sophistiqués capables de traduire des séquences biologiques en une histoire migratoire cohérente. L'enjeu scientifique majeur réside dans l'harmonisation de données souvent hétérogènes, car chaque laboratoire utilise des versions différentes du génome de référence, rendant la comparaison directe complexe. De plus, la sensibilité extrême des données génétiques impose une approche éthique rigoureuse, où la protection de la vie privée doit être intégrée dès la conception logicielle pour éviter tout stockage permanent d'informations identifiables.

1.1. Fondements Scientifiques et Données de Référence

La modélisation de l'ascendance repose sur l'utilisation du projet 1000 Genomes, qui constitue la base de référence pour l'entraînement de notre modèle d'apprentissage automatique. En se concentrant spécifiquement sur le Chromosome 22, le projet vise à capturer une variance génétique représentative tout en optimisant les ressources de calcul. Le cœur de l'analyse s'appuie sur une réduction de dimension via l'Analyse en Composantes Principales (PCA), permettant de projeter le profil génétique d'un individu dans un espace vectoriel où se distinguent les grandes super-populations mondiales, telles que les populations africaines, européennes ou asiatiques.

2. Cahier des Charges et Exigences du Système

Le cahier des charges du système définit les impératifs fonctionnels et techniques nécessaires pour garantir une inférence d'ascendance robuste et sécurisée. Sur le plan fonctionnel, l'application doit offrir une interopérabilité totale en acceptant nativement les formats de fichiers issus de 23andMe, AncestryDNA ainsi que le format standard VCF. Le système doit être capable de réaliser automatiquement l'extraction des 3 000 SNPs requis par le modèle sans exiger de manipulation complexe de la part de l'utilisateur. Une interface moderne développée sous React assure la fluidité de l'expérience, permettant de visualiser les résultats et les probabilités d'appartenance à chaque population de manière intuitive.

2.1. Spécifications Techniques et Contraintes de Développement

Techniquement, le moteur d'inférence doit impérativement intégrer un processus de liftover pour convertir les coordonnées génomiques de l'ancien référentiel hg19 vers la version moderne hg38, assurant ainsi la cohérence des données avec le modèle entraîné. L'architecture logicielle privilégie une séparation des tâches entre un backend en Node.js pour la gestion des flux et un script Python pour les calculs statistiques intensifs. Une contrainte critique de ce projet concerne la sécurité : aucune donnée utilisateur ne doit être conservée de manière persistante, le traitement s'effectuant intégralement en mémoire vive pour respecter le principe de Privacy-by-Design. Enfin, la gestion du développement a été structurée autour de l'outil Jira, permettant un suivi rigoureux des étapes de conception, de l'entraînement du modèle sur Google Colab jusqu'à son intégration finale.

3. Problématiques et besoins

Le projet de prédiction de l'ancestry à partir des données génomiques répond à la nécessité d'analyser et d'interpréter des informations génétiques complexes. Les données issues de 1000 Genomes ou de 23andMe sont volumineuses et hétérogènes, ce qui rend difficile l'identification manuelle des patterns génétiques et des relations entre populations. Le besoin principal est donc de concevoir un système capable de traiter efficacement ces données et de fournir des prédictions fiables sur l'ancestry des individus.

4. Objectifs

Les objectifs de ce projet sont multiples. Il s'agit d'abord de prétraiter et de normaliser les données génomiques afin de les rendre exploitables par des algorithmes de machine learning. Ensuite, le projet vise à développer un modèle capable de prédire l'ancestry d'un individu à partir de ses variations génétiques. Enfin, le projet entend évaluer les performances du modèle et proposer des recommandations pour son amélioration, tout en garantissant la confidentialité et la sécurité des données utilisées.

5. Déroulement du projet

Le déroulement du projet se structure en plusieurs étapes clés. La première étape consiste à collecter et préparer les données, suivie de l'analyse exploratoire pour comprendre leur structure et leur qualité. La deuxième étape concerne le développement des modèles de machine

learning et l'entraînement des algorithmes sur les jeux de données de référence. La troisième étape inclut l'évaluation des performances des modèles, l'interprétation des résultats et l'optimisation du système. Enfin, le projet se conclut par la rédaction d'un rapport détaillé et la présentation des résultats.

6. GANTT

Le planning du projet est organisé sur plusieurs semaines, avec des jalons correspondant à chaque étape du projet. La première phase (préparation des données) est prévue pour les deux premières semaines, suivie de l'analyse exploratoire et de la sélection des caractéristiques sur les deux semaines suivantes. Le développement et l'entraînement des modèles occupent les quatre semaines suivantes, tandis que l'évaluation et l'optimisation sont planifiées pour les deux dernières semaines. La rédaction du rapport et la préparation de la présentation finale complètent le projet.




Figure 1: Diagramme GANTT

7. Distribution de rôles

La répartition des rôles permet d'assurer l'efficacité et la coordination au sein de l'équipe. Chaque membre est responsable d'une étape spécifique, comme la collecte et le prétraitement des données, le développement et l'entraînement des modèles, ou l'évaluation et la documentation des résultats. Cette organisation garantit que toutes les tâches essentielles sont couvertes et que le projet progresse de manière structurée et collaborative.

8. Méthodologie de gestion

Le projet est mené selon une méthodologie Agile, qui favorise la flexibilité et l'adaptation aux imprévus. Les tâches sont suivies et planifiées à l'aide d'outils de gestion comme Jira, permettant de documenter l'avancement quotidien, d'identifier rapidement les problèmes et de réassigner les tâches si nécessaire. Cette approche assure une meilleure communication au sein de l'équipe et permet de livrer un projet de qualité dans les délais impartis.

9. Conclusion

Le cahier des charges constitue la base solide sur laquelle repose le projet de prédiction de l'ancestry à partir des données génomiques. Il permet d'identifier clairement les problématiques et les besoins, de définir des objectifs précis et de structurer le déroulement du projet de manière méthodique. La planification via le GANTT, la répartition des rôles et la méthodologie de gestion assurent une organisation efficace et un suivi rigoureux des différentes étapes.

Cette approche structurée garantit que le projet sera mené de manière coordonnée, tout en respectant les contraintes de temps et de qualité. Elle facilite également l'adaptation face aux imprévus et permet de tirer le meilleur parti des ressources disponibles. En définitive, le cahier des charges constitue un outil essentiel pour atteindre les objectifs du projet et assurer sa réussite.

Chapitre 2 :

Exploration des fondamentaux et des domaines de l'intelligence artificielle

1. Domaines de l'intelligence artificielle

Les domaines de l'intelligence artificielle regroupent l'ensemble des approches permettant de concevoir des systèmes capables de reproduire certaines capacités humaines telles que l'apprentissage, le raisonnement et l'analyse de données. Ces domaines s'appuient principalement sur l'apprentissage automatique, qui permet aux machines d'apprendre à partir de données, ainsi que sur l'apprentissage profond, basé sur les réseaux de neurones artificiels. Grâce à ces techniques, l'intelligence artificielle est aujourd'hui utilisée pour résoudre des problèmes complexes nécessitant le traitement de grandes quantités d'informations.

Dans le domaine scientifique, et plus particulièrement en bio-informatique, l'intelligence artificielle joue un rôle central dans l'analyse des données biologiques. Elle permet d'exploiter efficacement les données génomiques afin d'identifier des patterns génétiques et de réaliser des prédictions fiables. Dans ce projet, les méthodes d'intelligence artificielle sont utilisées pour la prédiction de l'ancestry à partir du génome, ce qui illustre l'importance de ces domaines dans l'analyse et l'interprétation des données génétiques.



Figure 2: Domaines de l'intelligence artificielle

2. Machine Learning

Le machine learning, ou apprentissage automatique, est un domaine fondamental de l'intelligence artificielle qui permet aux systèmes informatiques d'apprendre automatiquement à partir des données sans être explicitement programmés. Il repose sur l'analyse de données

afin d'identifier des relations et des motifs cachés, ce qui permet de réaliser des tâches telles que la classification, la prédiction ou la reconnaissance de formes.

Dans le cadre de la bio-informatique, le machine learning est particulièrement adapté au traitement des données génomiques, qui sont souvent volumineuses et complexes. En utilisant des algorithmes d'apprentissage automatique, il est possible d'exploiter les variations génétiques, notamment les SNPs, pour différencier les populations et prédire l'ancestry d'un individu. Ainsi, le machine learning constitue un outil essentiel pour l'analyse et l'interprétation des données génétiques dans ce projet.




Figure 3: Processus Machine Learning

3. Les méthodes de machine learning

Le machine learning comprend plusieurs approches qui permettent aux systèmes informatiques d'apprendre à partir des données et de réaliser des prédictions ou classifications. Chaque méthode possède ses spécificités et son domaine d'application.

3.1. Apprentissage supervisé

L'apprentissage supervisé utilise des données étiquetées pour entraîner un modèle. L'algorithme apprend à associer des entrées à des sorties connues, ce qui permet de prédire des

résultats pour de nouvelles données. Cette méthode est largement utilisée en bio-informatique pour la classification des populations ou la prédiction de traits génétiques à partir de SNPs.

3.2. Apprentissage non supervisé

L'apprentissage non supervisé analyse des données sans étiquettes pour identifier des structures, des regroupements ou des motifs cachés. Il est particulièrement utile pour la découverte de relations entre les individus ou pour regrouper des échantillons génomiques selon leur similarité.

3.3. Apprentissage semi-supervisé

L'apprentissage semi-supervisé combine des données étiquetées et non étiquetées. Cette approche est efficace lorsque les données étiquetées sont rares ou coûteuses à obtenir, ce qui est fréquent dans les projets génomiques.

3.4. Apprentissage par renforcement

L'apprentissage par renforcement consiste à entraîner un agent à prendre des décisions optimales en interagissant avec un environnement et en recevant des récompenses ou pénalités. Bien que moins utilisé en bio-informatique, il peut être appliqué dans des simulations biologiques ou pour optimiser des processus complexes.




Figure 4: Les méthodes de machine learning

4. Intelligence artificielle dans le domaine de la santé

L'intelligence artificielle occupe aujourd'hui une place importante dans le domaine de la santé grâce à sa capacité à analyser de grandes quantités de données médicales et biologiques. Elle permet d'améliorer le diagnostic, la prévention et le suivi des patients en exploitant des informations complexes issues de différentes sources, telles que les données cliniques, les images médicales et les données génomiques.

En bio-informatique, l'intelligence artificielle est largement utilisée pour l'analyse des données génétiques et la compréhension des maladies. Les techniques de machine learning facilitent l'identification de marqueurs génétiques associés à certaines pathologies et contribuent au développement de la médecine personnalisée. Dans ce contexte, l'utilisation de l'intelligence artificielle pour la prédiction de l'ancestry génétique permet d'apporter un soutien important à la recherche médicale, notamment pour l'étude de la diversité génétique et de son impact sur la santé.

5. Avantages et limites des systèmes intelligents dans le domaine de la santé

Les systèmes intelligents offrent de nombreux avantages dans le domaine de la santé, notamment grâce à leur capacité à traiter rapidement de grandes quantités de données médicales et biologiques. Ils permettent d'améliorer la précision du diagnostic, d'optimiser la prise de décision médicale et de soutenir les professionnels de santé dans l'analyse des données complexes. Ces systèmes contribuent également au développement de la médecine personnalisée en adaptant les traitements aux caractéristiques spécifiques de chaque patient.

Cependant, l'utilisation des systèmes intelligents dans le domaine de la santé présente également certaines limites. La qualité des résultats dépend fortement de la qualité et de la représentativité des données utilisées pour l'apprentissage des modèles. De plus, les questions liées à la confidentialité des données médicales, à l'interprétabilité des modèles et aux aspects éthiques constituent des défis majeurs. Ces limites montrent que, malgré leur potentiel important, les systèmes intelligents doivent être utilisés comme des outils d'aide à la décision et non comme des substituts au jugement humain.

6. Ingénierie des caractéristiques et réduction de dimensionnalité

Un défi majeur de l'IA appliquée à la génomique est la "malédiction de la dimensionnalité". Avec des milliers de SNPs (Single Nucleotide Polymorphisms) par échantillon, le modèle risque le surapprentissage (overfitting). L'Analyse en Composantes Principales (PCA) intervient ici comme une technique de compression d'information essentielle. Elle transforme un large ensemble de variables corrélées en un nombre restreint de variables décorrélées appelées composantes principales. En bioinformatique, les deux premières composantes (PC1 et PC2) capturent souvent les gradients géographiques mondiaux, permettant de projeter la complexité du génome humain sur une carte bidimensionnelle lisible.

7. Classification Statistique et Inférence de Probabilités

Une fois les dimensions réduites, le domaine de la classification probabiliste prend le relais. La Régression Logistique Multinomiale est utilisée pour modéliser la probabilité qu'un individu appartienne à l'une des cinq super-populations (AFR, AMR, EAS, EUR, SAS). Contrairement à un classifieur "dur" qui donnerait une réponse unique, cette approche probabiliste est cruciale pour gérer les cas d'individus métissés (admixture). Elle permet de quantifier l'incertitude et d'offrir une réponse nuancée, reflétant la réalité biologique où les frontières génétiques sont souvent continues plutôt que discrètes.

8. Domaines d'application : De la recherche à la mise en production

L'exploration de ces domaines montre que l'IA ne se limite pas à l'algorithmique pure, mais englobe également le déploiement. L'IA opérationnelle (MloReady) nécessite une intégration fluide entre le modèle mathématique (Python) et l'interface utilisateur (React/Node.js). Ce pont permet de rendre des concepts abstraits, comme les vecteurs de probabilités, accessibles via des visualisations interactives. En automatisant l'extraction de "features" à partir de fichiers hétérogènes (23andMe, VCF), l'IA transforme la donnée brute en une information décisionnelle, ouvrant la voie à des applications futures en médecine personnalisée et en pharmacogénomique.

9. Conclusion

À travers ce chapitre, nous avons présenté les principaux domaines de l'intelligence artificielle, ainsi que son rôle dans le domaine de la santé et de la bio-informatique. L'accent a été mis sur

l'importance du machine learning et des systèmes intelligents dans l'analyse de données complexes, en particulier les données génomiques.

Cette étude montre que l'intelligence artificielle constitue un outil puissant pour améliorer la compréhension des données biologiques et soutenir la prise de décision médicale. Toutefois, malgré ses nombreux avantages, son utilisation reste confrontée à certaines limites, notamment en matière de qualité des données, d'éthique et de protection de la vie privée. Ces éléments soulignent la nécessité d'une utilisation responsable et encadrée des systèmes intelligents, en particulier dans des applications sensibles telles que la prédiction de l'ancestry génétique.

Chapitre 3 : Élaboration et Préparation du Dataset

1. Introduction du Dataset

Un dataset, ou ensemble de données, est une collection organisée d'informations qui peuvent être analysées et exploitées pour en tirer des connaissances ou construire des modèles prédictifs. Dans le cadre de ce projet, le dataset regroupe des informations génomiques, telles que les variations nucléotidiques individuelles (SNPs), qui sont essentielles pour comprendre la diversité génétique des populations. Le rôle principal du dataset est de fournir la matière première nécessaire à l'apprentissage des modèles de machine learning. Sans des données fiables et représentatives, il serait impossible de détecter les patterns génétiques, de prédire l'ancestry d'un individu ou d'évaluer la performance du système. Ainsi, le dataset constitue le fondement de toute analyse bio-informatique, car il permet de transformer des informations brutes en connaissances exploitables et de garantir la précision et la robustesse des modèles développés.




Figure 5: Préparation et téléchargement des données

2. Préparation et téléchargement des données

Pour constituer le dataset du projet, nous avons utilisé les données du projet 1000 Genomes, qui sont disponibles publiquement sous forme de fichiers VCF (Variant Call Format). Ces

fichiers contiennent les variations génétiques, notamment les SNPs et les INDELs, pour chacune des 22 paires de chromosomes. Le code utilisé permet de télécharger automatiquement ces fichiers pour tous les chromosomes, ainsi que leurs index correspondants, à partir des serveurs FTP officiels.

Une fois les fichiers récupérés, ils sont concaténés pour créer un fichier unique contenant toutes les informations génomiques des individus étudiés. Cette étape est réalisée à l'aide de l'outil *bcftools*, qui permet de manipuler et de fusionner les fichiers VCF tout en conservant l'intégrité des données. La création d'un fichier consolidé facilite le prétraitement ultérieur, l'analyse statistique et l'application des modèles de machine learning pour la prédiction de l'ancestry. Ce processus assure que le dataset est complet, cohérent et prêt à être exploité pour les étapes suivantes du projet.




Figure 6: Téléchargement des données

3. Méthodes de nettoyage du dataset

Le nettoyage des données génomiques est une étape cruciale pour assurer la qualité et la fiabilité des analyses. Plusieurs méthodes sont utilisées pour préparer le dataset avant son exploitation par les algorithmes de machine learning.

A. Suppression des variants non bialléliques

Les SNPs bialléliques sont les plus fréquents et les plus informatifs pour la prédiction de l'ancestry. Les variants non bialléliques, qui présentent plus de deux allèles, peuvent compliquer l'analyse et introduire des erreurs. Leur suppression permet de simplifier le dataset et d'améliorer la qualité des modèles.

B. Filtrage des valeurs manquantes

Certaines positions génomiques peuvent contenir des données manquantes pour certains individus. Ces valeurs peuvent biaiser l'apprentissage des modèles. Le filtrage consiste à éliminer les SNPs ou les individus présentant un taux élevé de données manquantes, afin de conserver un dataset cohérent et fiable.

C. Suppression des duplications et incohérences

Des doublons ou des incohérences peuvent apparaître lors de la concaténation des fichiers VCF ou de la collecte des données. Leur identification et suppression garantissent que chaque individu et chaque variant sont représentés une seule fois, ce qui est essentiel pour éviter des biais dans l'apprentissage.

D. Vérification de la qualité globale

Après ces étapes, une vérification globale du dataset est réalisée pour s'assurer que les données sont homogènes, que les formats sont corrects et que le fichier final est exploitable par les modèles de machine learning. Cette étape inclut également la normalisation et la mise en forme des données si nécessaire.

4. Prétraitement et normalisation

Avant l'application des algorithmes de classification, il est essentiel de préparer et d'harmoniser les données génomiques provenant de sources hétérogènes telles que les fichiers VCF, 23andMe ou AncestryDNA. Cette étape de prétraitement vise à rendre les données comparables et exploitables par les modèles de machine learning.

4.1. Normalisation des données

La normalisation des données est réalisée à l'aide d'un **StandardScaler**, qui permet de centrer et de réduire les valeurs de chaque SNP. Cette opération est particulièrement importante en

génomique, car les variants peuvent présenter des variances très différentes. En uniformisant l'échelle des données, chaque SNP contribue de manière équitable à l'analyse, ce qui améliore la stabilité et la performance des modèles.

$$X'_i = \frac{X_i - \mu}{\sigma} = \frac{X_i - X_{\text{mean}}}{X_{\text{std}}}$$

StandardScaler

Figure 7: Normalisation des données

4.2. Imputation des valeurs manquantes

Les valeurs manquantes ou inconnues sont remplacées par 0, correspondant à l'allèle de référence. Cette approche simple d'imputation garantit que la matrice de données reste complète, ce qui est nécessaire pour les calculs matriciels et l'entraînement des modèles. Bien que cette méthode ne capture pas la variabilité potentielle des valeurs manquantes, elle constitue une solution efficace pour maintenir la cohérence et la structure du dataset avant l'apprentissage automatique.

5. Réduction de dimension : PCA (Analyse en Composantes Principales)

Avant la phase de prédiction, le script applique une Analyse en Composantes Principales (PCA) sur les données normalisées, à l'aide de la commande `pca.transform(data_scaled)`. Cette étape est essentielle pour traiter les données génomiques, qui présentent souvent un nombre très élevé de SNPs par rapport au nombre d'individus, un phénomène connu sous le nom de "fléau de la dimension".

A. Utilisation PCA

La PCA permet de condenser l'information contenue dans des milliers de SNPs en un nombre réduit de variables synthétiques appelées composantes principales. Cela simplifie l'espace de données et rend l'entraînement des modèles de machine learning plus rapide et plus efficace, tout en limitant le risque de surapprentissage.

B. Utilité en génétique des populations

En génétique, les premières composantes principales (PC1, PC2...) reflètent souvent des relations biologiques et historiques entre les populations, comme la proximité géographique ou les migrations ancestrales. Ainsi, l'application de la PCA permet non seulement de réduire la dimensionnalité des données, mais aussi de mettre en évidence des patterns génétiques pertinents pour la prédiction de l'ancestry.

6. Choix de l'algorithme

Le choix de l'algorithme de classification est une étape critique dans la conception du système de prédiction de l'ancestry, car il influence directement la précision et la robustesse des résultats. Les données génomiques présentent des caractéristiques spécifiques : un nombre très élevé de SNPs par rapport au nombre d'individus, des relations non-linéaires entre les variants et une diversité génétique importante entre les populations. Ces particularités orientent le choix vers des algorithmes capables de gérer de grandes dimensions et des interactions complexes.

A. Algorithmes envisagés

Parmi les algorithmes les plus adaptés, on retrouve Random Forest et Support Vector Machine (SVM). Le Random Forest est particulièrement efficace pour traiter des données à forte dimensionnalité et pour gérer les relations non-linéaires, tout en offrant une interprétabilité grâce à l'importance des variables. Le SVM, quant à lui, est capable de créer des frontières de décision optimales dans des espaces multidimensionnels et est très performant pour la classification avec peu d'échantillons par rapport au nombre de caractéristiques.

B. Sorties probabilistes et fiabilité

Un autre critère de choix est la capacité de l'algorithme à produire des sorties probabilistes, plutôt que des étiquettes brutes. Cette fonctionnalité permet de mesurer le degré de confiance des prédictions pour chaque population (AFR, EUR, EAS, etc.), ce qui est essentiel pour l'interprétation scientifique des résultats et pour la prise de décision dans un contexte bio-informatique.

C. Adaptation aux données génomiques

Enfin, le choix de l'algorithme tient compte de l'intégration avec les étapes précédentes du pipeline, comme la PCA pour la réduction de dimension et le prétraitement des SNPs. Un algorithme robuste doit non seulement classer correctement, mais aussi être compatible avec

les données prétraitées, normalisées et encodées, afin d'assurer la cohérence et la performance globale du système.

5. Bibliothèques utilisées

Le développement du système de prédiction de l'ancestry repose sur plusieurs bibliothèques Python essentielles, qui facilitent la manipulation des données, l'application des algorithmes de machine learning et la gestion des fichiers génomiques.



Figure 8: bibliothèque sys python

sys Fournit des fonctions et variables permettant d'interagir avec l'interpréteur Python, notamment pour gérer les arguments des scripts et contrôler l'exécution des programmes.



Figure 9: bibliothèque json python

json Permet de lire et d'écrire des fichiers au format JSON (JavaScript Object Notation), un format structuré et standard pour stocker ou échanger des données entre applications.



Figure 10: bibliothèque joblib python

joblib : Bibliothèque spécialisée pour sauvegarder et charger des objets Python volumineux, notamment les modèles de machine learning pré-entraînés, de manière rapide et efficace.



Figure 11: bibliothèque Numpy python

numpy : Fournit des outils puissants pour la manipulation de tableaux et de matrices numériques, ainsi que pour les calculs mathématiques et statistiques à grande échelle.



pandas : Permet de gérer et d'analyser facilement des données tabulaires grâce à des structures de données flexibles comme les DataFrames, facilitant le filtrage, l'agrégation et la transformation des données.



Figure 13: bibliothèque os python

os : Fournit des fonctions pour interagir avec le système de fichiers et le système d'exploitation, permettant de naviguer, créer, modifier ou supprimer des fichiers et des dossiers.



Figure 14:
bibliothèque pvlift
python

pylifter : Bibliothèque spécialisée pour convertir les coordonnées génomiques entre différentes versions du génome de référence (par exemple hg19 vers hg38), assurant la compatibilité des données avec les modèles pré-entraînés.

5.1 Gestion des fichiers et des données

La bibliothèque **os** est utilisée pour interagir avec le système de fichiers, permettant de naviguer, créer ou modifier des dossiers et fichiers. **sys** est employée pour gérer les arguments du script et contrôler l'exécution du programme. **json** sert à lire et écrire des fichiers de configuration ou de résultats au format structuré, facilitant l'échange et la documentation des informations.

5.2 Manipulation et traitement des données

Pour le traitement des données tabulaires et numériques, les bibliothèques **pandas** et **numpy** sont utilisées. Pandas permet de gérer efficacement des tableaux de données, d'effectuer des opérations de filtrage, de fusion ou d'agrégation. Numpy, quant à lui, offre des outils puissants pour les calculs matriciels et la manipulation de vecteurs et matrices, indispensables pour les étapes de prétraitement, normalisation et réduction de dimension.

5.3 Chargement et utilisation des modèles

La bibliothèque **joblib** est utilisée pour sauvegarder et charger des modèles de machine learning pré-entraînés. Dans ce projet, elle permet de charger le modèle final via un bundle, garantissant

que le pipeline de prédiction peut être exécuté directement sans nécessiter un nouvel entraînement.

5.4 Conversion des coordonnées génomiques

Enfin, la bibliothèque **pyliftover** joue un rôle crucial pour la compatibilité des données génomiques. Elle permet de convertir les coordonnées des variants génétiques d'un standard ancien (hg19) vers le standard actuel (hg38), assurant que les fichiers clients soient compatibles avec le modèle pré-entraîné. Cette étape est indispensable pour maintenir la précision des prédictions sur des données provenant de sources diverses.

6. Architecture du système : Analyse de l'ancestralité génomique

L'architecture du système est conçue pour traiter efficacement des données génomiques volumineuses et complexes, en s'appuyant sur une structure modulaire en **trois couches**. Cette organisation découplée permet de séparer les différentes responsabilités et d'assurer la robustesse et la maintenabilité du système. Une telle structuration facilite également l'évolution du projet, permettant d'ajouter de nouvelles fonctionnalités sans perturber les composants existants, et assure une meilleure traçabilité des données et des processus.

A. Interface utilisateur

La couche frontend est développée avec **React**, offrant à l'utilisateur la possibilité de téléverser des fichiers génomiques au format .txt ou .csv. Ces fichiers sont ensuite transmis au backend via une **requête POST**, garantissant une interaction fluide et sécurisée. L'interface est conçue pour être intuitive, permettant aux utilisateurs non spécialistes de suivre facilement le processus d'analyse et d'accéder rapidement aux résultats. De plus, elle intègre des contrôles de validation pour vérifier le format des fichiers avant leur envoi, réduisant ainsi les risques d'erreurs dans le pipeline.

B. Backend et orchestration

Le backend repose sur Node.js (Express) et assure la réception et la gestion sécurisée des fichiers grâce au middleware Multer. Il instancie dynamiquement le moteur Python chargé de l'analyse bioinformatique. La communication entre le backend JavaScript et le moteur Python se fait via les flux standards (stdout) et le format JSON, assurant une interopérabilité optimale entre les deux environnements. Cette couche joue également un rôle clé dans la gestion des

erreurs et le suivi des traitements, permettant de journaliser chaque opération pour garantir la traçabilité et la reproductibilité des analyses.

C. Pipeline bioinformatique

Le moteur Python exécute un pipeline rigoureux comprenant plusieurs étapes clés :

- **Détection et conversion des formats** : identification du type de fichier et conversion des coordonnées génomiques de hg19 vers hg38 via PyLiftover.
- **Prétraitement et réduction de dimension** : normalisation des données et application de la PCA pour condenser l'information génétique en variables synthétiques.
- **Classification** : prédiction de l'ancestralité via un modèle de machine learning, ici une régression logistique.

Chaque étape est optimisée pour traiter de grands volumes de données de manière efficace et reproductible. Le pipeline assure également un contrôle de qualité, en détectant les anomalies et en prévenant la propagation d'erreurs jusqu'à la prédiction finale.

D. Visualisation des résultats

Une fois la prédiction effectuée, les résultats sont renvoyés au frontend sous format JSON, puis traduits en visualisations interactives grâce à la bibliothèque Recharts, offrant à l'utilisateur une interprétation claire et immédiate de ses données génomiques. Ces visualisations permettent de comparer les probabilités d'ancestralité entre différentes populations et de mettre en évidence les tendances ou les signatures génétiques spécifiques à chaque individu. Elles constituent un outil pédagogique et scientifique, rendant les analyses accessibles même aux utilisateurs non experts en bioinformatique.

E. Points clés de l'architecture

- **Modularité** : séparation nette entre la capture des données (React), l'orchestration (Node.js) et le calcul scientifique (Python), ce qui facilite la maintenance et les mises à jour du système.
- **Interopérabilité** : communication fluide entre JavaScript et Python via JSON et les flux standards, assurant que les données circulent sans perte d'information et que les résultats restent cohérents.

- **Pipeline bioinformatique intégré** : toutes les étapes critiques de traitement et de normalisation des données génomiques sont assurées avant la prédiction par apprentissage automatique, garantissant fiabilité et précision.

Ces points soulignent l'efficacité de l'architecture pour gérer des données complexes, tout en restant flexible et évolutive pour intégrer de futures améliorations ou de nouveaux types d'analyses génomiques.




Figure 15: Architecture du système

7. Analyse des Diagrammes UML

Le système est documenté à travers deux vues UML complémentaires : une vue fonctionnelle à l'aide du diagramme de cas d'utilisation et une vue dynamique via le diagramme de séquence. Ces deux diagrammes permettent de comprendre à la fois ce que fait le système du point de vue utilisateur et comment il fonctionne techniquement en interne. Ensemble, ils décrivent le cycle

de vie complet d'une analyse génomique, depuis l'interaction initiale jusqu'à la restitution des résultats.

7.1. Diagramme de Cas d'Utilisation (Use Case)

Le diagramme de cas d'utilisation met en évidence les interactions entre l'utilisateur et le système à un niveau abstrait, sans entrer dans les détails techniques d'implémentation. Il permet d'identifier clairement les fonctionnalités principales offertes par la plateforme et les responsabilités du système vis-à-vis de l'utilisateur.

- **Acteur principal**

L'acteur principal est l'utilisateur final, qui souhaite analyser ses données génomiques afin d'obtenir une estimation de son ancestralité. Ce diagramme montre que l'utilisateur est au centre du processus et qu'il interagit uniquement avec des fonctionnalités de haut niveau, sans être exposé à la complexité bioinformatique sous-jacente.

- **Processus de téléversement**

Le cas d'utilisation « *Téléverser le fichier de génotype* » inclut une étape obligatoire de validation du fichier. Cette validation garantit que les données fournies respectent les formats attendus (23andMe, CSV, etc.) et limite les erreurs lors du traitement. Elle joue un rôle essentiel dans la fiabilité du système et la qualité des résultats générés.

- **Consultation des résultats**

L'action « *Voir les résultats* » déclenche automatiquement l'exécution de la prédiction (*Run Prediction*). Cela souligne que les résultats ne sont pas statiques mais générés dynamiquement à partir des données fournies par l'utilisateur. Cette approche garantit que chaque analyse est personnalisée et calculée à la demande, renforçant la pertinence des prédictions.




Figure 16: Diagramme de Cas d'Utilisation

7.2. Diagramme de Séquence

Le diagramme de séquence décrit le déroulement temporel des interactions entre les différents composants logiciels du système. Il met en évidence l'ordre des échanges et la collaboration entre le frontend, le backend et le moteur de calcul Python.

- **Interaction Frontend / Backend**

Le processus débute lorsque l'utilisateur soumet un fichier génomique via l'interface React. Celui-ci est envoyé au serveur Node.js à travers une requête `POST /predict`. Cette étape marque le point d'entrée officiel des données dans le système et initie l'ensemble du pipeline d'analyse.

- **Orchestration par Node.js**

Le backend Node.js assure un rôle central d'orchestrateur. Il valide le fichier reçu, le stocke temporairement et lance un processus enfant exécutant le moteur de prédiction Python. Cette séparation des responsabilités permet d'isoler les calculs lourds du serveur web, améliorant ainsi les performances et la stabilité globale du système.

- **Intelligence du moteur Python**

Le moteur Python constitue le cœur scientifique de l'application et se distingue par plusieurs capacités clés :

- **Adaptabilité** : le script analyse l'en-tête du fichier pour identifier son format et adapter automatiquement le traitement. Les fichiers anciens sont convertis de hg19 vers hg38 grâce à **pyliftover**, assurant une cohérence avec le modèle entraîné.
- **Prétraitement** : les modèles sérialisés (`.joblib`) sont chargés, les SNPs sont alignés et les valeurs manquantes sont gérées par imputation. Cette étape garantit que les données sont exploitables par les algorithmes de machine learning.
- **Inférence** : les données normalisées subissent une transformation par **StandardScaler** et **PCA**, avant que le modèle de **régression logistique** ne produise des probabilités d'ancestralité pour chaque population.
- **Nettoyage et visualisation**

Une fois les résultats renvoyés au backend sous forme de **JSON**, Node.js supprime les fichiers temporaires afin de préserver la confidentialité des données génétiques. Le frontend exploite ensuite ces résultats pour générer des graphiques à barres interactifs, permettant à l'utilisateur d'interpréter facilement les proportions d'ancestralité estimées.




Figure 17: Diagramme de Séquence

8. Architecture Réseau et Sécurité des Données

L'infrastructure du système est conçue selon un modèle de segmentation réseau séparant clairement une Zone Publique et un Environnement Serveur Privé. Cette approche permet d'isoler les composants critiques et de réduire la surface d'attaque. L'utilisateur interagit exclusivement avec la zone publique à travers un navigateur web via l'application React, sans accès direct aux ressources internes du système.

La communication entre le frontend et le backend s'effectue via les protocoles HTTP/HTTPS sur le port 3000, assurant la transmission sécurisée des données. L'utilisation de protocoles standards facilite l'interopérabilité tout en permettant l'ajout de mécanismes de chiffrement et de contrôle d'accès. Ainsi, seules les requêtes explicitement autorisées peuvent atteindre le serveur applicatif.

8.1. Traitement des requêtes et orchestration serveur

Une fois la requête `POST /predict` reçue, le serveur **Node.js Express** prend en charge l'orchestration des traitements au sein de l'environnement privé. Il agit comme un point de contrôle central, validant les entrées avant de déclencher les étapes de calcul. Cette organisation permet de maîtriser le flux de données et d'éviter toute exécution non contrôlée.

- **Gestion des flux**

Le fichier téléversé est sauvegardé dans un espace de stockage temporaire, soit sur le disque local, soit en mémoire. Cette étape est strictement transitoire et vise à permettre l'analyse sans conserver durablement les données sensibles. Le serveur instancie ensuite un processus fils Python chargé du traitement bioinformatique.

- **Communication inter-processus**

L'échange entre Node.js et Python repose sur les **flux standards**, garantissant une communication simple et efficace. Les paramètres d'exécution sont transmis via `stdin`, tandis que les résultats sont récupérés via `stdout` au format **JSON**. Ce mécanisme assure une séparation claire entre l'orchestration et le calcul scientifique.

- **Confidentialité et nettoyage des données**

Afin de respecter les exigences de confidentialité liées aux données génomiques, le système implémente un mécanisme de suppression automatique. Dès que les résultats sont transmis au client, les fichiers temporaires sont détruits. Cette politique limite fortement les risques de fuite de données ou d'accès non autorisé.

8.2. Garantie de sécurité et isolation des composants

Grâce à cette architecture, le moteur de calcul Python et les données génomiques brutes ne sont jamais exposés directement à l'internet public. L'accès est strictement contrôlé par le backend, qui agit comme une barrière de sécurité. Cette isolation constitue une couche de protection essentielle contre les attaques externes et contribue à la fiabilité globale du système.




Figure 18: Architecture Réseau et Sécurité des Données

9. Architecture Décisionnelle et Modèles BI

L'architecture décisionnelle (Business Intelligence) du système est conçue pour concilier analyse de données à grande échelle **et** respect strict de la confidentialité selon une approche *Privacy-First*. Aucune donnée génétique brute n'est conservée de manière persistante, ce qui réduit considérablement les risques éthiques et réglementaires. Seules des métadonnées anonymisées, issues du processus de prédiction, sont stockées à des fins analytiques et décisionnelles.

Cette séparation claire entre données opérationnelles sensibles et données analytiques garantit la conformité aux bonnes pratiques de protection des données, tout en permettant un suivi précis des performances et de l'usage du système.

9.1. Le Modèle de Données : Schéma en Étoile

Afin de permettre une analyse multidimensionnelle rapide de type OLAP (Online Analytical Processing), le système adopte un schéma en étoile, largement utilisé dans les architectures BI. Ce modèle facilite les requêtes analytiques complexes tout en maintenant de bonnes performances, même sur de grands volumes de données.

Le schéma est centré sur l'événement de prédiction, considéré comme l'unité fondamentale d'analyse.

Table de Fait : `FACT_PREDICTION_EVENT`

La table de fait centralise les indicateurs quantitatifs clés liés à chaque prédiction effectuée par le système. Elle stocke notamment le score de confiance (probabilité comprise entre 0 et 1), le temps de traitement en millisecondes ainsi que le statut de succès ou d'échec de l'opération. Ces métriques permettent d'évaluer à la fois la performance algorithmique et la robustesse du système.

Dimensions Clés

- **DIM_TIME**

Cette dimension permet une analyse temporelle fine des prédictions, par heure, jour, mois ou année. Elle est essentielle pour détecter des tendances d'utilisation, des pics de charge ou des périodes de forte activité.

- **DIM_ANCESTRY**

Elle regroupe les différentes populations détectées (par exemple EUR, AFR, EAS), accompagnées de descriptions détaillées. Cette dimension facilite les analyses statistiques globales sur la diversité des résultats produits par le système.

- **DIM_FILE_SOURCE**

Cette dimension assure le suivi des formats et sources de fichiers utilisés (23andMe, 1000 Genomes, etc.). Elle permet d'identifier les sources dominantes et d'orienter les futures optimisations du système.




Figure 19: Le Modèle de Données : Schéma en Étoile

9.2. Architecture BI et Flux de Données

Le pipeline décisionnel est totalement découplé de l'application principale afin de garantir qu'aucune donnée ADN ne soit introduite dans l'entrepôt de données. Cette approche renforce la sécurité et permet de faire évoluer l'architecture BI indépendamment du cœur applicatif.

- **Génération de logs**

Le serveur Node.js génère exclusivement des **logs statistiques anonymisés**, tels que les temps de réponse, les scores de prédiction et les formats de fichiers utilisés. Aucune information génétique ou identifiante n'est enregistrée à ce niveau.

- **Couche ETL (Extract – Transform – Load)**

Un processus ETL extrait les logs bruts, les transforme pour les aligner sur le schéma en étoile, puis les charge dans une base de données analytique. Cette étape garantit la cohérence, la qualité et l'exploitabilité des données décisionnelles.

- **Visualisation et reporting**

Les données consolidées sont analysées via des outils de BI tels que **Power BI** ou **Tableau**. Ces plateformes permettent aux analystes et décideurs de suivre les indicateurs clés et d'orienter les choix techniques et stratégiques.




Figure 20: Architecture BI et Flux de Données

9.3. Indicateurs de Performance et Visualisations

Le système décisionnel repose sur un ensemble de **KPIs stratégiques**, regroupés en trois catégories principales. Ces indicateurs offrent une vision globale de l'utilisation, de la performance et de la fiabilité du système.




Figure 21: Indicateurs de Performance et Visualisations

- **Répartition globale de l’ancestralité (Pie Chart)**

Cette visualisation fournit une vue synthétique des populations détectées sur l’ensemble des analyses réalisées. Elle permet d’identifier les tendances dominantes, comme une prédominance européenne ou africaine dans les échantillons traités.

- **Popularité des formats de fichiers (Bar Chart)**

Ce graphique met en évidence les sources de données les plus utilisées par les utilisateurs. L’analyse montre, par exemple, une forte domination du format 23andMe, ce qui peut guider les priorités d’optimisation et de compatibilité.




Figure 22: Popularité des formats de fichiers Bar Chart

- **Métriques de santé du système**

Ces indicateurs surveillent le bon fonctionnement global de la plateforme, incluant le temps moyen de traitement, le taux d’erreurs serveur (HTTP 500) et la latence de la file d’attente. Ils sont essentiels pour anticiper les incidents et améliorer la qualité de service.




Figure 23:kpi structure

10.Conclusion

Ce chapitre a permis de présenter l'architecture décisionnelle et les modèles de Business Intelligence mis en place pour accompagner le système d'analyse de l'ancestralité génomique. L'approche adoptée repose sur une séparation stricte entre les données opérationnelles sensibles et les données analytiques, garantissant ainsi le respect des principes de confidentialité et de protection des données génétiques.

Le recours à un schéma en étoile, centré sur l'événement de prédiction, offre une structure performante et flexible pour l'analyse multidimensionnelle des métadonnées. Associée à un pipeline BI découplé et à une couche ETL dédiée, cette architecture permet de suivre efficacement les performances du système, les usages utilisateurs et les indicateurs de qualité de service, sans compromettre la sécurité des données.

Enfin, l'intégration d'outils de visualisation et de tableaux de bord décisionnels fournit aux acteurs techniques et décisionnels une vision synthétique et exploitable du fonctionnement global du système. Cette architecture BI constitue ainsi un levier essentiel pour l'amélioration continue de la plateforme, l'optimisation des performances et l'aide à la prise de décision stratégique.

Chapitre 4 : Implémentation et résultats

1. Implémentation Technique

L'implémentation concrétise une architecture robuste, dans laquelle chaque composant assure un traitement fluide et sécurisé des données génomiques. Cette organisation modulaire permet de gérer efficacement les fichiers volumineux, tout en garantissant la sécurité et la confidentialité des informations sensibles. Le pipeline complet est conçu pour être transparent pour l'utilisateur final, tout en intégrant les meilleures pratiques en bioinformatique et en machine learning.

2. Courbe d'Apprentissage (Learning Curve)

La courbe d'apprentissage permet d'analyser l'évolution de la performance du modèle en fonction du nombre d'exemples utilisés pour l'entraînement. Elle constitue un outil essentiel pour évaluer la capacité du modèle à apprendre à partir des données et à généraliser correctement sur de nouveaux échantillons. Dans le contexte de la prédiction d'ancestralité génomique, cette analyse est particulièrement importante en raison de la forte dimensionnalité des données génétiques.




Figure 24: Learning Curve

2.1. Analyse de la performance

- **Convergence des scores**

Le score d'entraînement (Training score) démarre à un niveau élevé, autour de 0.88, lorsque le nombre d'exemples est réduit. Cette performance élevée s'explique par la capacité du modèle à mémoriser les données lorsqu'elles sont peu nombreuses. À mesure que la taille de l'échantillon augmente, le score diminue progressivement pour se stabiliser autour de 0.76 avec environ 1600 exemples, indiquant une convergence vers une performance plus réaliste.

- **Capacité de généralisation**

Le score de validation croisée (Cross-validation score) montre une progression régulière, passant d'environ 0.66 à près de 0.74. Le rapprochement progressif des courbes d'entraînement et de validation suggère que le modèle généralise correctement sur des données non vues. Cette observation indique l'absence de surapprentissage significatif (*overfitting*), ce qui est un point clé pour un système destiné à être utilisé par des utilisateurs réels.

- **Compromis biais–variance**

L'écart résiduel entre les deux courbes reste faible une fois la convergence atteinte. Cela traduit un bon équilibre entre le biais et la variance du modèle, confirmant que la combinaison StandardScaler + PCA + Régression Logistique constitue un pipeline adapté à la prédiction d'ancestralité génomique.

3. Interface Utilisateur

3.1. Interface Utilisateur et Sécurité

L'application propose une interface utilisateur épurée et intuitive, permettant le téléversement de fichiers aux formats `.txt`, `.csv` ou `.vcf`. Cette simplicité favorise l'accessibilité du système à des utilisateurs non spécialistes, tout en assurant une expérience utilisateur fluide.

Une attention particulière est portée à la confidentialité : un message explicite informe que les données sont traitées uniquement en mémoire et supprimées immédiatement après la prédiction.

Cette stratégie garantit qu'aucun fichier génomique n'est conservé de manière permanente, réduisant ainsi les risques de fuite ou d'utilisation non autorisée.

The screenshot shows the 'Genetic Ancestry Predictor' web interface. At the top, there's a title 'Genetic Ancestry Predictor' and a link 'How this works'. The main content area is a light blue box containing a white card. The card has the following elements: a paragraph explaining that users can upload raw genotype files from 23andMe, AncestryDNA, or VCF format, and that the app will extract required SNPs; a 'Privacy Protected' section with a blue checkmark icon and text stating that data is processed in memory and deleted immediately after prediction, and that no genotype file is stored; a 'Select Genotype File (.txt, .csv, .vcf)' section with a 'Parcourir...' button and the text 'Aucun fichier sélectionné.'; and a large blue 'Predict Ancestry' button. At the bottom of the page, a small disclaimer states: 'This tool is for educational and research purposes only. Results should not be used for medical or legal decisions.'

Figure 25: Interface Utilisateur

3.2. Orchestration et Flux de Traitement

Le backend Node.js joue le rôle de chef d'orchestre. Lorsqu'un utilisateur téléverse un fichier, par exemple au format 23andMe ou 1000 Genomes, le serveur valide le document pour vérifier sa conformité. Le fichier est ensuite stocké temporairement avant le lancement d'un processus enfant Python chargé du traitement.

- **Moteur Python**

Le moteur détecte automatiquement le format via l'analyse de l'en-tête du fichier, effectue la conversion des coordonnées génomiques (hg19 vers hg38) si nécessaire, gère les valeurs manquantes par imputation et applique le modèle de régression logistique après une transformation PCA. Cette chaîne de traitement assure la cohérence des données et la fiabilité des prédictions.

- **Nettoyage**

Dès que les résultats sont renvoyés au backend au format le serveur Node.js supprime le fichier temporaire du stockage local ou de la mémoire. Ce mécanisme protège la vie privée de l'utilisateur et garantit que les données sensibles ne sont jamais exposées.

4. Analyse des Résultats et KPIs

Pour piloter l'efficacité du système et suivre sa performance, un pipeline ETL (Extract – Transform – Load) transforme les métadonnées issues des prédictions en indicateurs stratégiques, stockés dans un entrepôt de données organisé selon un schéma en étoile. Cette structure permet d'effectuer des analyses multidimensionnelles et d'obtenir des insights précis sur l'usage et la performance de la plateforme.

4.1. Indicateurs de Performance (KPIs)

Le système suit quatre grandes catégories de métriques pour assurer la qualité scientifique et opérationnelle :

- **Métriques Business**

Suivi du volume de trafic, incluant le nombre d'utilisateurs actifs quotidiennement et le nombre d'uploads par heure. Ces indicateurs permettent d'évaluer l'adoption de la plateforme et d'anticiper les besoins en ressources serveur.

- **Usage des Formats**

Analyse de la popularité des formats de fichiers (23andMe vs 1000 Genomes) ainsi que du taux d'erreurs par type de fichier. Ces données aident à orienter les optimisations futures et à améliorer la compatibilité avec les sources les plus utilisées.

- **Santé du Système**

Surveillance de l'uptime de l'API, de la latence moyenne de traitement (en millisecondes) et du taux d'erreurs serveur (HTTP 500). Ces KPIs garantissent la fiabilité et la robustesse du système.

- **Métriques Scientifiques**

Statistiques sur les populations détectées et score de confiance moyen des prédictions. Ces informations permettent d'évaluer la précision et la cohérence du modèle de classification de l'ancestralité.

4.2. Visualisations Décisionnelles

Les données agrégées sont utilisées pour générer des rapports visuels clairs, facilitant l'interprétation et l'analyse globale :

- **Distribution Génomique**

La répartition mondiale montre une prédominance de l'ancestralité européenne (42 %) et africaine (28 %) dans les échantillons traités, offrant une vue synthétique des tendances globales.

- **Popularité des Formats**

Le format 23andMe est le plus utilisé avec environ 850 uploads, suivi par le format 1000 Genomes (environ 320 uploads). Ces informations permettent de prioriser les efforts de support et d'optimisation technique.

- **Résultat Individuel**

Pour chaque échantillon, l'utilisateur reçoit une probabilité détaillée par population, par exemple *South Asian 37.0%*, *European 33.2%*, facilitant la compréhension de ses origines et offrant une interprétation personnalisée des résultats.



Figure 26: Visualisations Décisionnelles Interface Utilisateur

5. Interprétation des Résultats

Les résultats obtenus montrent que le système est capable de fournir des prédictions d'ancestralité cohérentes et interprétables, avec des probabilités bien réparties entre les différentes populations. La prédominance de certaines ancestralités, telles que les populations européenne et africaine, reflète en partie la composition des bases de données de référence utilisées pour l'entraînement du modèle. Cela indique que le modèle apprend efficacement les structures génétiques majeures présentes dans les données disponibles.

Cependant, ces résultats doivent être interprétés avec prudence, car les probabilités générées représentent des estimations statistiques et non des certitudes absolues. La qualité des prédictions dépend fortement de la représentativité des données d'apprentissage et de la qualité des fichiers génomiques fournis par les utilisateurs.

6. Limites du Modèle

Malgré ses performances satisfaisantes, le modèle présente certaines limites. L'utilisation d'une régression logistique, bien que robuste et interprétable, peut réduire la capacité à capturer des relations non linéaires complexes entre les variants génétiques. De plus, la réduction de dimension par PCA, tout en améliorant les temps de calcul, peut entraîner une perte d'informations biologiques fines.

Par ailleurs, le modèle est sensible aux déséquilibres entre populations dans les données de référence. Les groupes sous-représentés peuvent voir leurs prédictions moins précises, ce qui constitue un biais potentiel dans l'interprétation des résultats.

7. Contraintes Techniques et Opérationnelles

Sur le plan technique, le traitement de fichiers génomiques volumineux impose des contraintes en termes de mémoire et de temps de calcul, notamment lors des étapes de conversion des coordonnées génomiques et d'imputation des valeurs manquantes. Bien que l'architecture modulaire permette une bonne gestion de ces contraintes, la montée en charge avec un grand nombre d'utilisateurs simultanés pourrait nécessiter des mécanismes supplémentaires de parallélisation ou de mise à l'échelle.

De plus, la dépendance à des formats spécifiques (23andMe, 1000 Genomes) limite actuellement la compatibilité avec d'autres sources de données génétiques, ce qui peut restreindre l'adoption du système

8. Conclusion

Ce chapitre a présenté l'implémentation technique du système ainsi que l'analyse des résultats obtenus à travers des indicateurs de performance pertinents. L'architecture mise en place, fondée sur une séparation claire entre l'interface utilisateur, l'orchestration backend et le moteur de calcul Python, permet d'assurer un traitement efficace, sécurisé et respectueux de la confidentialité des données génomiques.

Les résultats obtenus démontrent la robustesse du pipeline bioinformatique et la pertinence des choix méthodologiques, notamment l'utilisation de la réduction de dimension par PCA et d'un modèle de régression logistique. Le suivi des KPIs techniques, business et scientifiques offre une vision globale du fonctionnement du système et confirme sa capacité à fournir des prédictions fiables et interprétables. Ainsi, cette implémentation constitue une base solide pour un système d'analyse d'ancestralité évolutif, performant et orienté utilisateur.

Chapitre 5 : Conclusion Générale

Conclusion Générale

Le projet *Genetic Ancestry Inference* avait pour objectif principal de concevoir une plateforme complète capable de transformer des données génomiques brutes et complexes en informations claires et interprétables pour l'utilisateur final, tout en respectant des exigences strictes de sécurité et de confidentialité. Les résultats obtenus confirment la pertinence de l'approche proposée : le pipeline automatisé d'harmonisation des données, combiné à un modèle de régression logistique après réduction de dimension par PCA, a atteint une précision de validation croisée d'environ 74 %, démontrant une bonne capacité de généralisation sans surapprentissage significatif. L'architecture logicielle modulaire, fondée sur la séparation entre le frontend React, le backend Node.js et le moteur de calcul Python, assure une orchestration fluide, robuste et scalable des traitements, tandis que l'approche *Privacy-by-Design* garantit que les données ADN sont uniquement traitées en mémoire et supprimées immédiatement après usage. Dans le contexte de la génomique personnelle, ce projet constitue un outil pédagogique pertinent pour la compréhension de la diversité génétique humaine, et représente, sur le plan académique et professionnel, une expérience déterminante dans notre formation en Master IA, en confrontant les modèles théoriques aux contraintes réelles de production telles que l'interopérabilité des formats, la sécurité des données sensibles et la mise en œuvre de pipelines prêts pour un usage réel. Enfin, plusieurs perspectives d'évolution se dégagent, notamment l'exploration de modèles plus avancés comme le deep learning, l'enrichissement des populations de référence afin de réduire les biais, l'extension vers des applications en médecine personnalisée telles que la pharmacogénomique, ainsi que la mise à l'échelle du système pour supporter une charge élevée d'utilisateurs simultanés.

Bibliographie

- 1000 Genomes Project Consortium.** (2015). *A global reference for human genetic variation*. Nature.
- Genome Reference Consortium.** *Human Genome Assembly GRCh38 (hg38)*.
- National Center for Biotechnology Information (NCBI).** *Variation Call Format (VCF) Specification*.
- Li, H.** *The Sequence Alignment/Map format and SAMtools/BCFtools*. Bioinformatics. (Pour l'utilisation de `bcftools`).
- Pedregosa, F. et al.** (2011). *Scikit-learn: Machine Learning in Python*. (Pour les implémentations de PCA, StandardScaler et Logistic Regression).
- McKinney, W.** (2010). *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference. (Pour la bibliothèque `pandas`).
- Harris, C. R. et al.** (2020). *Array programming with NumPy*. Nature.
- Node.js Foundation.** *Node.js v20+ Documentation*. (Express.js et gestion des processus enfants).
- Meta Platforms, Inc.** *React Documentation*. (Développement de l'interface utilisateur).
- Atlassian.** *Jira Software: Agile Project Management*.
- PyLiftover.** *Library for converting genomic coordinates between assemblies*.
- Joblib Development Team.** *Joblib: running Python functions as pipeline jobs*.